

# Báo cáo kỹ thuật: BudgetRAG và RLAIIF cho lựa chọn retrieval-context

Branch: feature/rlaif-retrieval-context-v0

Ngày 04 tháng 06 năm 2026

|                          |                                                                                                                                                                                        |
|--------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Mốc code hiện tại        | Schema, rlaif-build, rlaif-label-answers, rlaif-label-contexts, rlaif-reward -answer-labels, rlaif-split, rlaif-train, rlaif-eval, answer/context-label summaries và Qwen KV estimates |
| Mốc schema               | fdefb63 – feat(rlaif): add retrieval-context schemas                                                                                                                                   |
| Mốc kế hoạch             | c634bd3 – docs(plan): update rlaif retrieval-context roadmap                                                                                                                           |
| Trạng thái test gần nhất | 187 passed                                                                                                                                                                             |

## 1 Tóm tắt

BudgetRAG hiện đã chuyển từ một hệ thống so sánh chiến thuật context-budget thủ công sang một nền tảng có thể tạo dữ liệu RLAIIF offline. Điểm thay đổi quan trọng là action không còn chỉ là “giữ bao nhiêu context”, mà là một **retrieval-context action**: chọn retrieval strategy, fusion strategy, top-k, context policy, budget, adaptive profile, selected context action và generator model.

Các commit gần nhất tạo nền cho Phase 1C.3:

- fdefb63: định nghĩa schema cho action, answer feedback, context feedback, scalar reward và preference.
- 78cf83d: thêm rlaif-build để đọc BudgetRAG output và ghi các dataset RLAIIF chuẩn hóa.
- Hardening hiện tại: chuẩn hóa AI judge provenance thành ai\_judge và cho phép full-context/legacy action không có explicit budget.
- Answer judge hiện tại: thêm rlaif-label-answers với resume, progress logging, JSON repair và guardrail không biến invalid/missing label thành score 0.
- Context judge hiện tại: thêm rlaif-label-contexts để label sufficient context, selected/redundant/irrelevant chunks, missing evidence và context quality với cùng cơ chế dry-run/resume/JSON repair; thêm script summary và report template cho context labels.
- Reward/preference hiện tại: thêm rlaif-reward để ghi reward, preference và summary từ dataset RLAIIF đã chuẩn hóa, gồm optional -answer-labels để dùng AI-judge labels hợp lệ.
- Offline selector hiện tại: thêm rlaif-split, rlaif-train và rlaif-eval cho held-out query evaluation với fixed, cheapest, best-average và oracle-logged baselines.

Đây vẫn là bước dữ liệu và đánh giá offline. Hệ thống **chưa** thay adaptive-heuristic bằng learned policy, **chưa** train contextual bandit thật, **chưa** có full context-level judge run, và **chưa** thực hiện KV pruning runtime. Ranh giới này quan trọng để tránh “fake RL”.

## 2 Bối cảnh nghiên cứu

Project nên được đặt tại giao điểm của sáu cụm nghiên cứu: RAG, evaluation, prompt/context compression, KV-cache compression, GraphRAG/retrieval strategy selection, và RLAIIF/contextual bandit.

RAG đặt nền cho việc kết hợp parametric memory với retrieved external memory trong generation [7]. BEIR cung cấp chuẩn đánh giá retrieval đa domain và cho thấy retriever không có một cấu hình tốt tuyệt đối trên mọi tập [13]. RAGAS bổ sung góc nhìn evaluation ở cấp RAG, đặc biệt là faithfulness, answer relevance và context relevance [4].

BudgetRAG khác các prompt compression chung như LLMLingua, LongLLMLingua và Selective Context [5, 6, 9] ở chỗ compression được coi là một **action trong bài toán retrieval-grounded decision**. Policy phải quyết định giữ bằng chứng nào dưới ràng buộc chất lượng, token, latency và estimated KV, thay vì chỉ nén prompt theo một mục tiêu cố định.

Các hướng KV-cache như H2O, StreamingLLM, KIVI, SnapKV và PyramidKV [15, 14, 11, 10, 2] can thiệp sâu hơn vào runtime/model cache. BudgetRAG hiện đi theo hướng ít xâm lấn hơn: giảm context trước inference, sau đó dùng context-level RLAIIF labels làm bằng chứng cho bước evidence mask/KV retention proof of concept.

GraphRAG nhấn mạnh vai trò của graph-based text index cho các truy vấn global hoặc sensemaking [3]. Vì vậy action space của Phase 1D phải bao gồm retrieval strategy, không chỉ context budget.

RLAIIF và preference learning cung cấp cách biến feedback từ AI judge thành reward/preference [1, 12]. Với BudgetRAG, feedback này không nhằm alignment chatbot tổng quát, mà nhằm chấm **context sufficiency** và **grounded answer quality**. Vì mỗi query chỉ cần một lựa chọn retrieval-context ở một bước, offline contextual bandit là formulation đầu tiên hợp lý hơn PPO/GRPO [8].

## 3 Định vị so với related work

| Research line      | Trọng tâm                                 | Vị trí của BudgetRAG                                                     |
|--------------------|-------------------------------------------|--------------------------------------------------------------------------|
| RAG                | Retrieve external evidence cho generation | Thêm bài toán phân bổ context theo tài nguyên và chất lượng.             |
| BEIR/RAGAS         | Đánh giá retrieval/RAG                    | Mở rộng metric bằng token, latency, estimated KV và feedback provenance. |
| Prompt compression | Prompt/context compression                | Biến compression thành query-level decision action trong RAG.            |
| KV-cache methods   | Runtime KV compression/pruning            | Bắt đầu model-agnostic, sau đó dùng evidence labels cho KV retention.    |
| RLAIIF/DPO         | AI/preference feedback                    | Label context sufficiency và grounded answer quality.                    |
| Contextual bandit  | Học one-step action policy từ feedback    | Học retrieval-context action dưới reward có quality guardrail.           |

## 4 Trạng thái implementation hiện tại

### 4.1 Schema

Module `rag_bench.rlaif_schema` định nghĩa:

- `RetrievalContextAction`: state/action ở cấp query, bao gồm retriever, fusion, top-k, context policy, optional budget, adaptive profile, selected context policy/budget và generator model. Full-context hoặc legacy action thiếu explicit budget dùng `budget_chars=None`.
- `RlaifAnswerFeedback`: feedback cấp answer với provenance gold, ragas, ai\_judge, mimo\_judge cho backward compatibility, heuristic, missing.
- `RlaifContextFeedback`: feedback cấp context với sufficient, selected/redundant/irrelevant chunks, missing evidence, minimality score, evidence support score và context quality score.
- `RlaifReward`: reward tách quality/support/token/latency/KV/error/unsupported claim.
- `RlaifPreference`: preference type cho context-policy, retrieval-context và context-sufficiency.

Action id deterministic là một điểm đúng hướng: id gồm benchmark, query id, retrieval strategy, fusion strategy, top-k, context policy, budget, adaptive profile, selected context action và generator model, nhưng loại source run id để nhiều lần chạy cùng cấu hình có thể merge được.

### 4.2 Dataset builder

Command hiện có:

```
uv run rag-bench rlaif-build \  
  --inputs benchmark_results/budgetrag/<matrix-run> \  
  --output-dir benchmark_results/rlaif/<run-name>
```

Builder thực hiện:

- discover mọi `query_results.jsonl` trong input file hoặc directory;
- convert từng row thành normalized action qua `action_from_budgetrag_row`;
- giữ observation payload: answer text, retrieved records, context metrics, retrieval metrics, retrieval metadata, KV estimate, latency, token usage, generation error/retry/rate-limit metadata;
- tạo answer feedback theo thứ tự: gold EM/F1, RAGAS fields, AI judge fields, rồi missing;
- ghi summary với provenance counts, missing reason counts, generation error count và invalid rows.

Quan trọng: missing feedback không bị gán score 0. Generation skipped, generation error và missing answer được ghi bằng `missing_reason` riêng, trong đó generation error được đánh dấu `ambiguous=True`.

### 4.3 Answer judge labeler

Command hiện có:

```
uv run rag-bench rlaif-label-answers \
  --actions benchmark_results/rlaif/<run-name>/rlaif_actions.jsonl \
  --output benchmark_results/rlaif/<run-name>/rlaif_answer_labels_mimo.jsonl \
  --judge-provider mimo \
  --judge-model mimo-v2.5-pro \
  --resume \
  --json-retries 1 \
  --max-completion-tokens 4096
```

rlaif-label-answers chỉ judge từ question, answer và retrieved context đã log; prompt cấm browse và external knowledge. Output ghi incremental nên có thể resume sau khi kernel/local process bị ngắt. Nếu model trả invalid JSON, empty content, thiếu answer hoặc thiếu context, label được ghi là ambiguous với quality\_score=null; không có path nào biến lỗi judge thành score 0.

Script scripts/summarize\_rlaif\_labels.py đọc rlaif\_answer\_labels.jsonl và báo label count, valid/invalid JSON, ambiguous labels, judge provider/model counts, score mean/std, unsupported-claim penalty và correlation với RAGAS answer relevancy khi có rlaif\_feedback.jsonl. Template report nằm ở docs/reports/phase1d\_rlaif\_answer\_labels\_template.md.

### 4.4 Context judge labeler

Command hiện có:

```
uv run rag-bench rlaif-label-contexts \
  --actions benchmark_results/rlaif/<run-name>/rlaif_actions.jsonl \
  --output benchmark_results/rlaif/<run-name>/rlaif_context_labels_mimo.jsonl \
  --judge-provider mimo \
  --judge-model mimo-v2.5-pro \
  --resume \
  --json-retries 1 \
  --max-completion-tokens 4096
```

rlaif-label-contexts judge chỉ từ question, optional logged answer và retrieved chunks đã log. Output ghi sufficient, selected\_chunk\_ids, redundant\_chunk\_ids, irrelevant\_chunk\_ids, missing\_evidence, minimality\_score, evidence\_support\_score và context\_quality\_score. Nếu judge trả chunk id không thuộc action row, id đó bị drop và ghi vào metadata. Missing context, invalid JSON, empty completion hoặc judge error đều thành ambiguous label với score null, không thành 0.

Script scripts/summarize\_rlaif\_context\_labels.py đọc rlaif\_context\_labels.jsonl và báo valid/invalid JSON, ambiguous labels, sufficiency, missing evidence, selected/redundant/irrelevant chunk counts, dropped unknown chunk-id count, context quality, evidence support và minimality statistics. Template report nằm ở docs/reports/phase1d\_rlaif\_context\_labels\_template.md.

### 4.5 Reward/preference builder

Command hiện có:

```
uv run rag-bench rlaif-reward \
  --actions benchmark_results/rlaif/<run-name>/rlaif_actions.jsonl \
  --feedback benchmark_results/rlaif/<run-name>/rlaif_feedback.jsonl \
  --answer-labels benchmark_results/rlaif/<run-name>/rlaif_answer_labels_mimo.jsonl \
  --output-dir benchmark_results/rlaif/<run-name> \
  --quality-weight 0.75 \
  --support-weight 0.10 \
  --token-weight 0.05 \
  --latency-weight 0.05 \
  --kv-weight 0.05 \
  --min-reward-delta 0.03 \
  --max-quality-regret 0.02
```

Khi có `-answer-labels`, reward builder dùng AI-judge labels hợp lệ làm feedback chính. Nếu label invalid, ambiguous, errored hoặc thiếu quality, builder fallback về feedback gốc như RAGAS khi có và ghi rõ merge reason trong metadata. Nếu cả hai nguồn đều thiếu quality hợp lệ, reward vẫn là null, không phải 0.

Builder ghi ba artifact:

- `rlaif_rewards.jsonl`: reward row cho mỗi action, gồm reward, reward components, weights, provenance và reward mode.
- `rlaif_preferences.jsonl`: pairwise preferences cho context-policy và retrieval-context groups.
- `rlaif_reward_summary.md`: coverage, reward modes, preference types, skip reasons và weights.

Guardrail quan trọng: nếu feedback thiếu quality hoặc ambiguous, reward vẫn được ghi để audit nhưng `reward=null`; nó không bị biến thành 0. Preference chỉ được tạo giữa các action có reward thật, cùng query group, reward gap đủ lớn, và không vi phạm `max-quality-regret`. Vì vậy action rẻ hơn không được thắng nếu answer quality tụt rõ.

## 4.6 Offline selector baselines

Command hiện có:

```
uv run rag-bench rlaif-split \
  --rewards benchmark_results/rlaif/<run-name>/rlaif_rewards.jsonl \
  --preferences benchmark_results/rlaif/<run-name>/rlaif_preferences.jsonl \
  --output-dir benchmark_results/rlaif/<run-name>/split_seed42 \
  --train-ratio 0.8 \
  --seed 42

uv run rag-bench rlaif-train \
  --rewards benchmark_results/rlaif/<run-name>/split_seed42/train_rewards.jsonl \
  --preferences benchmark_results/rlaif/<run-name>/split_seed42/train_preferences.jsonl \
  --output benchmark_results/rlaif/<run-name>/split_seed42/rlaif_policy.json

uv run rag-bench rlaif-eval \
  --rewards benchmark_results/rlaif/<run-name>/split_seed42/eval_rewards.jsonl \
  --policy benchmark_results/rlaif/<run-name>/split_seed42/rlaif_policy.json \
  --out-md benchmark_results/rlaif/<run-name>/split_seed42/rlaif_eval_summary.md \
  --split-manifest benchmark_results/rlaif/<run-name>/split_seed42/split_manifest.json
```

`rlaif-split` chia theo `benchmark + query_id`, không chia random theo action row. Tất cả action của cùng một query luôn nằm cùng train hoặc eval split. Preference chỉ được giữ nếu cả chosen/rejected action cùng nằm trong train hoặc cùng nằm trong eval; preference cắt ngang split bị drop và được đếm trong manifest.

`rlaif-train` hiện tạo bốn baseline offline:

- `fixed`: chọn action signature có nhiều reward thật nhất, tie-break bằng reward trung bình.
- `cheapest`: chọn action có chi phí token + latency + estimated KV thấp nhất trong logged query group.
- `best-average`: chọn action signature khả dụng có reward trung bình cao nhất trong dữ liệu train.
- `oracle-logged`: upper bound offline, chọn action có reward quan sát cao nhất trong cùng query group.

`rlaif-eval` báo cáo mean reward, mean quality, normalized token/latency/KV cost, selected action distribution, scored coverage, selection coverage và paired oracle gap. Khi truyền `-split-manifest`, summary ghi `held_out_query_eval=true`. Policy artifact luôn ghi `runtime_default_replacement=false`; nó là artifact đánh giá offline, không thay runtime default.

Held-out smoke hiện tại dùng split seed 42 trên reward rows đã join RAGAS. Split có 27 train queries, 7 eval queries, 178 train reward rows, 14 eval reward rows, 572 train preferences và 6 eval preferences. Trên eval set, `best-average` đạt mean reward 0.425 và mean quality 0.538 với coverage 0.889; `cheapest` đạt mean reward 0.377 và mean quality 0.476 với coverage 1.0. Kết quả này củng cố trade-off chính: tiết kiệm token/KV đơn thuần làm giảm quality, còn selector tốt cần giữ quality guardrail.

## 5 Hai điểm đã harden trước reward/preference

Pasted review đã chỉ ra hai điểm yếu hợp lý cần sửa trước khi xây reward/preference builder. Hai điểm này đã được xử lý trong hardening hiện tại.

### 5.1 Judge provenance cho non-MiMo

Trước hardening, `_feedback_from_judge` map provider khác mimo thành heuristic. Điều này có thể làm DeepSeek hoặc Groq judge bị ghi nhầm là heuristic. Cách sửa đã chọn là:

- mở rộng provenance thành `ai_judge`;
- lưu provider cụ thể ở `judge_provider`;
- lưu model cụ thể ở `judge_model`;
- giữ mimo\_judge trong schema để backward compatibility với artifact cũ.

Như vậy MiMo, DeepSeek, Groq hoặc judge LLM khác không bị trộn vào heuristic. heuristic chỉ còn dùng cho label không đến từ LLM judge.

### 5.2 Full-context/legacy action không có explicit budget

`RetrievalContextAction.budget_chars` trước đây là positive int bắt buộc. Với legacy/full action hoặc output cũ không có explicit budget, converter có thể invalid. Schema hiện cho phép:

`budget_chars: int | None`

Nếu `budget_chars=None`, action id vẫn ổn định và biểu diễn đúng “full-context” hoặc legacy baseline. Điều này hợp hơn với Phase 1D, vì baseline full/legacy phải có mặt trong action space thay vì bị loại vì thiếu metadata.

## 6 Local Qwen KV Estimate

Script `scripts/estimate_local_qwen_kv_cache.py` ước lượng KV-cache cho các model Qwen2.5 mà không load weights. Công thức dùng:

$$\text{KV bytes} = 2 * \text{layers} * \text{num\_key\_value\_heads} * \text{head\_dim} \\ * \text{seq\_len} * \text{batch\_size} * \text{dtype\_bytes}$$

Report `docs/reports/local_qwen_kv_estimates.md` hiện ghi bảng cho Qwen2.5 0.5B, 1.5B, 3B, 7B và 14B ở 1K, 2K, 4K, 8K, 16K, 32K và 128K tokens với batch size 1, dtype 2 bytes. Ví dụ analytical KV-cache của Qwen2.5-14B là khoảng 0.750 GiB ở 4K, 6.000 GiB ở 32K và 24.000 GiB ở 128K. Đây chỉ là KV-cache estimate; chưa bao gồm weights, activations, allocator fragmentation, paged-attention block overhead hoặc runtime server overhead.

## 7 Roadmap tiếp theo

Thứ tự tiếp theo nên giữ như sau:

1. **Hoàn tất answer judge run:** download output Kaggle, chạy `scripts/summarize_rlaif_labels.py`, rebuild reward bằng `-answer-labels`, rồi rerun `split/train/eval`.
2. **Context judge run:** chạy `rlaif-label-contexts` sau khi answer-label pipeline ổn, rồi dùng labels này để tạo context-sufficiency preferences.
3. **Context label report:** chạy `scripts/summarize_rlaif_context_labels.py` và điền `docs/reports/phase1d_rlaif_context_labels_template.md`.
4. **Richer RLAIIF labels:** thêm answer correctness, faithfulness, unsupported claims và context sufficiency trước khi học model phức tạp.
5. **Simple reward model/ranking baseline:** dùng feature table nhẹ khi reward/preference coverage đủ hơn baseline bảng.
6. **Contextual bandit thật:** chỉ sau khi offline eval cho thấy không làm giảm answer quality.

Guardrail chính phải giữ: learned RLAIIF/bandit policy không được thay adaptive-heuristic làm default runtime policy trước khi pass offline evaluation và quality guardrails. Web-search actions chỉ là live stress-test actions, không trộn với reproducible BEIR benchmark claims.

## 8 Kết luận

Repo hiện đã có engineering story tốt hơn trước: plan checkpoint, schema checkpoint, dataset builder checkpoint, reward/preference checkpoint, offline selector checkpoint và test suite pass. Bổ sung research grounding giúp báo cáo không còn giống một pipeline tự phát, mà đứng tại giao điểm của RAG evaluation, prompt/context compression, KV-cache compression, RLAIIF và contextual bandit learning.

Điểm cần làm ngay tiếp theo là hoàn tất judge runs và tăng coverage dữ liệu trước khi đi sang simple ranking model hoặc contextual bandit thật. Đây là đường đi đúng để RLAIIF trong project trở thành một cơ chế học action có dữ liệu và guardrail, không phải một nhãn “RL” gán sau.

## Tài liệu

- [1] Yuntao Bai, Saurav Kadavath, Sandipan Kundu, Amanda Askell, Jackson Kernion, Andy Jones, Anna Chen, Anna Goldie, Azalia Mirhoseini, Cameron McKinnon, Carol Chen, Catherine Olsson, Chris Olah, Danny Hernandez, Dawn Drain, Deep Ganguli, Dustin Li, Eli Tran-Johnson, Ethan Perez, Jamie Kerr, Jared Mueller, Jeffrey Ladish, Joshua Landau, Kamal Ndousse, Kamile Lukosuite, Liane Lovitt, Michael Sellitto, Nelson Elhage, Nicholas Schiefer, Nova DasSarma Mercado, Robert Lasenby, Robin Larson, Sam Ringer, Scott Johnston, Shauna Kravec, Sheer Showk, Stanislav Fort, Tamera Lanham, Timothy Telleen-Lawton, Tom Conerly, Tom Henighan, Tristan Hume, Samuel R. Bowman, Zac Hatfield-Dodds, Ben Mann, Dario Amodei, Nicholas Joseph, Sam McCandlish, Tom Brown, and Jared Kaplan. Constitutional ai: Harmlessness from ai feedback. *arXiv preprint arXiv:2212.08073*, 2022. <https://arxiv.org/abs/2212.08073>.
- [2] Zefan Cai, Yichi Zhang, Bofei Gao, Yuliang Liu, Tianyi Liu, Keming Lu, Wayne Xiong, Yue Dong, Baobao Chang, Junjie Hu, and Wen Xiao. Pyramidkv: Dynamic kv cache compression based on pyramidal information funneling. *arXiv preprint arXiv:2406.02069*, 2024. <https://arxiv.org/abs/2406.02069>.
- [3] Darren Edge, Ha Trinh, Newman Cheng, Joshua Bradley, Alex Chao, Apurva Mody, Steven Truitt, and Jonathan Larson. From local to global: A graph rag approach to query-focused summarization. *arXiv preprint arXiv:2404.16130*, 2024. <https://arxiv.org/abs/2404.16130>.
- [4] Shahul Es, Jithin James, Luis Espinosa-Anke, and Steven Schockaert. Ragas: Automated evaluation of retrieval augmented generation. *arXiv preprint arXiv:2309.15217*, 2023. <https://arxiv.org/abs/2309.15217>.
- [5] Huiqiang Jiang, Qian Wu, Chin-Yew Lin, Yuqing Yang, and Lili Qiu. Llmllingua: Compressing prompts for accelerated inference of large language models. *arXiv preprint arXiv:2310.05736*, 2023. <https://arxiv.org/abs/2310.05736>.
- [6] Huiqiang Jiang, Qian Wu, Xufang Luo, Dongsheng Li, Chin-Yew Lin, Yuqing Yang, and Lili Qiu. Longllmlingua: Accelerating and enhancing llms in long context scenarios via prompt compression. *arXiv preprint arXiv:2310.06839*, 2023. <https://arxiv.org/abs/2310.06839>.
- [7] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Kuttler, Mike Lewis, Wen-tau Yih, Tim Rocktaschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive nlp tasks. *arXiv preprint arXiv:2005.11401*, 2020. <https://arxiv.org/abs/2005.11401>.
- [8] Lihong Li, Wei Chu, John Langford, and Robert E. Schapire. A contextual-bandit approach to personalized news article recommendation. *arXiv preprint arXiv:1003.0146*, 2010. <https://arxiv.org/abs/1003.0146>.



- [9] Yucheng Li, Bo Dong, Frank Guerin, and Chenghua Lin. Compressing context to enhance inference efficiency of large language models. *arXiv preprint arXiv:2310.06201*, 2023. <https://arxiv.org/abs/2310.06201>.
- [10] Yuhong Li, Yingbing Huang, Bowen Yang, Bharat Venkitesh, Andrea Locatelli, Hanchen Ye, Tian Cai, Patrick Lewis, and Deming Chen. Snapkv: Llm knows what you are looking for before generation. *arXiv preprint arXiv:2404.14469*, 2024. <https://arxiv.org/abs/2404.14469>.
- [11] Zirui Liu, Jiayi Yuan, Hongye Jin, Shaochen Zhong, Zhaozhuo Xu, Vladimir Braverman, Beidi Chen, and Xia Hu. Kivi: A tuning-free asymmetric 2bit quantization for kv cache. *arXiv preprint arXiv:2402.02750*, 2024. <https://arxiv.org/abs/2402.02750>.
- [12] Rafael Rafailov, Archit Sharma, Eric Mitchell, Stefano Ermon, Christopher D. Manning, and Chelsea Finn. Direct preference optimization: Your language model is secretly a reward model. *arXiv preprint arXiv:2305.18290*, 2023. <https://arxiv.org/abs/2305.18290>.
- [13] Nandan Thakur, Nils Reimers, Andreas Ruckle, Abhishek Srivastava, and Iryna Gurevych. Beir: A heterogeneous benchmark for zero-shot evaluation of information retrieval models. *arXiv preprint arXiv:2104.08663*, 2021. <https://arxiv.org/abs/2104.08663>.
- [14] Guangxuan Xiao, Yuandong Tian, Beidi Chen, Song Han, and Mike Lewis. Efficient streaming language models with attention sinks. *arXiv preprint arXiv:2309.17453*, 2023. <https://arxiv.org/abs/2309.17453>.
- [15] Zhenyu Zhang, Ying Sheng, Tian Zhou, Tian Chen, Lianmin Zheng, Ruisi Cai, Zhao Song, Yuandong Tian, Christopher Re, Clark Barrett, Zhangyang Wang, and Beidi Chen. H2o: Heavy-hitter oracle for efficient generative inference of large language models. *arXiv preprint arXiv:2306.14048*, 2023. <https://arxiv.org/abs/2306.14048>.