

BudgetRAG / MemAlign-Qwen: Resource-Aware Retrieval and Context Allocation for Grounded LLM Inference

Báo cáo tổng kết tiến độ thực tập

Tác giả: Sơn Tùng Kiều

Giảng viên hướng dẫn: bổ sung

Đơn vị: bổ sung

<https://github.com/sontungkieu/true-chat>

Ngày 05 tháng 06 năm 2026

Tóm tắt nội dung

Retrieval-Augmented Generation (RAG) giúp mô hình ngôn ngữ lớn trả lời dựa trên bằng chứng bên ngoài, nhưng việc đưa nhiều ngữ cảnh vào prompt làm tăng số token, độ trễ và dung lượng KV-cache ước tính. Báo cáo này tổng kết tiến độ thực tập của dự án BudgetRAG / MemAlign-Qwen, với mục tiêu nghiên cứu cách chọn retrieval strategy, context policy và context budget dưới ràng buộc chất lượng, token, latency và estimated KV-cache cost. Dự án bắt đầu từ nền tảng benchmark RAG, registry retriever, CLI và metric retrieval; sau đó mở rộng sang BudgetRAG fixed context policies, adaptive heuristic profiles, generation feedback, RAGAS/MiMo answer labels, RLAIIF-style answer/context labels, reward/preference construction và offline selector/bandit-style baselines. Kết quả chính gồm: 192 MiMo answer labels hợp lệ, 192 MiMo context labels đã merge với 177 clean usable labels, sufficiency rate 0.591, trung bình 1.276 selected chunks và 3.708 irrelevant chunks; context reward ablation làm thay đổi 140/192 reward rows và tăng preference count từ 722 lên khoảng 950; selector evaluation nhiều seed cho thấy shrinkage-smoothed best average là baseline full-coverage mạnh nhất hiện tại nhưng learned selectors vẫn data-limited. Báo cáo cũng trình bày direct pairwise RLAIIF audit, multi-judge targeted audit với DeepSeek/Groq, KV-cache estimates cho Qwen2.5 và các giới hạn: đây là AI feedback, offline logged-candidate evaluation, chưa phải human preference learning, online RL, DPO/PPO/GRPO hoặc runtime KV pruning.

Mục lục

1	Giới thiệu	3
2	Phát biểu bài toán	3
3	Related Work	3
3.1	RAG và đánh giá RAG	3
3.2	Prompt và context compression	4
3.3	KV-cache compression/pruning	4
3.4	Graph/hybrid retrieval	4
3.5	RLAIIF, preference learning và contextual bandit	4
4	Tổng quan hệ thống	4

5	Phase 1A: nền tảng benchmark RAG	5
6	Phase 1B: BudgetRAG context policies	5
7	Phase 1C: adaptive heuristic profiles	5
8	Phase 1C.3: generation feedback layer	6
9	Phase 1D: RLAIIF reward và preference pipeline	7
10	Kết quả chính	7
10.1	Full MiMo context labels	7
10.2	Context reward ablation	7
10.3	Multi-seed selector results	8
11	Pairwise RLAIIF audit và calibration	8
12	Offline selector / bandit baselines	9
13	Multi-judge targeted audit	9
14	KV-cache motivation và Qwen estimates	10
15	Giới hạn	10
16	Công việc tiếp theo	11
A	Chi tiết Phase 1B–1C	11
B	Reward ablation đầy đủ	11
C	CLI chronology	12
D	Các report nguồn	12

1 Giới thiệu

RAG kết hợp retrieval với generation để mô hình có thể dựa vào bằng chứng ngoài thay vì chỉ dựa vào parametric memory [8]. Trong các hệ thống thực tế, cách đơn giản thường là lấy top-k tài liệu rồi đưa toàn bộ hoặc phần lớn context vào prompt. Cách này dễ triển khai nhưng có ba vấn đề: context có thể chứa nhiều nhiễu, prompt dài làm tăng chi phí/độ trễ, và với local LLM thì sequence length dài làm tăng KV-cache memory.

Dự án BudgetRAG / MemAlign-Qwen đặt câu hỏi: với cùng một query và tập retrieved candidates, ta nên giữ bằng chứng nào, với ngân sách context nào, và bằng chiến thuật retrieval/context nào để vẫn trả lời grounded nhưng giảm token, latency và estimated KV-cache cost? Đây không phải bài toán chỉ “nén prompt”, mà là bài toán chọn action retrieval–context có trade-off giữa quality và resource.

Động lực MemAlign-Qwen đến từ triển khai local/privacy-constrained. Trong bối cảnh tài liệu riêng tư hoặc semi-private, người dùng không muốn gửi toàn bộ tài liệu lên dịch vụ bên ngoài. BudgetRAG hiện giảm context trước inference; các nhãn context-level RLAIIF sau này có thể làm cơ sở cho evidence mask hoặc KV retention trong local Qwen. Báo cáo không claim production deployment, mà ghi nhận hạ tầng, kết quả offline và các giới hạn hiện tại.

2 Phát biểu bài toán

Với query q và tập candidates C từ retriever, hệ thống cần chọn một action a :

$$a = (\text{retrieval_strategy}, \text{fusion_strategy}, \text{context_policy}, \text{budget}, \text{adaptive_profile}, \text{generator_model})$$

Mục tiêu là tối đa hóa grounded answer quality trong khi tối thiểu hóa token cost, latency cost và estimated KV-cache cost. Reward offline hiện được biểu diễn ở mức khái niệm:

$$R = w_q Q + w_s S - w_t T - w_l L - w_k K - P_{\text{unsupported}} - P_{\text{error}}$$

Trong đó Q là answer quality/correctness, S là evidence/context support, T là normalized token cost, L là normalized latency cost, K là normalized estimated KV cost, còn các penalty xử lý unsupported claims và generation/judge errors.

State gồm query features, retrieval diagnostics, action metadata và cost estimates. Action gồm retrieval strategy, fusion strategy, context policy, budget, adaptive profile và model. Đây là **offline logged-candidate evaluation**: policy chỉ chọn trong các candidates đã được log. Nó chưa phải online RL, chưa deploy thay runtime default, và mọi artifact selector đều giữ runtime_default_replacement=false.

3 Related Work

3.1 RAG và đánh giá RAG

RAG đặt nền cho việc kết hợp retrieved documents với sequence-to-sequence generation [8]. BEIR chỉ ra retrieval performance rất phụ thuộc domain và dataset, do đó cần benchmark nhiều tập thay vì tin một retriever duy nhất [14]. RAGAS bổ sung các metric RAG như answer relevancy và faithfulness [5]. Trong dự án này, BEIR-style retrieval metrics được dùng làm nền, còn RAGAS là proxy feedback ban đầu trước khi chuyển sang MiMo AI-judge labels.

3.2 Prompt và context compression

LLMLingua, LongLLMLingua và Selective Context nghiên cứu giảm độ dài prompt/context để tăng hiệu quả inference [6, 7, 10]. BudgetRAG khác ở formulation: compression là một phần của retrieval–context action và được đánh giá cùng answer quality, context sufficiency, token, latency và estimated KV cost.

3.3 KV-cache compression/pruning

H2O, StreamingLLM, KIVI, SnapKV và PyramidKV can thiệp trực tiếp vào cache hoặc attention để giảm memory/latency cho long-context generation [16, 15, 12, 11, 2]. BudgetRAG hiện làm bước trước inference: chọn context ngắn hơn hoặc tốt hơn. Runtime KV pruning được để cho future work; evidence labels từ RLAIIF context judge có thể trở thành mask cho sink/recent/evidence token retention sau này.

3.4 Graph/hybrid retrieval

GraphRAG nhấn mạnh graph-based index cho query-focused summarization và sensemaking [4]. Hybrid retrieval và Reciprocal Rank Fusion (RRF) là hướng quan trọng để kết hợp nhiều retriever [3]. Vì vậy action space của BudgetRAG cần bao gồm retrieval strategy và fusion strategy, nhưng kết quả hiện tại chủ yếu vẫn đến từ BM25 logged actions; chưa đủ để claim robust retrieval-strategy selection.

3.5 RLAIIF, preference learning và contextual bandit

Constitutional AI/RLAIIF dùng AI feedback để tạo preference/reward signal [1]; DPO trực tiếp tối ưu preference mà không cần reward model riêng [13]. Trong dự án này, RLAIIF được dùng hẹp hơn: AI judge label answer correctness/support và context sufficiency. Vì mỗi query/action là một quyết định một bước, offline contextual bandit-style selector là baseline hợp lý hơn PPO/GRPO ở giai đoạn dữ liệu nhỏ [9].

4 Tổng quan hệ thống

Pipeline hiện tại:

Query → retriever/graph/hybrid candidate retrieval → BudgetRAG context policy → generator → answer/context feedback → reward/preference rows → offline selector evaluation

Các thành phần code chính:

- rag-bench: CLI cho benchmark, BudgetRAG matrix, RLAIIF build/reward/split/train/eval.
- Retriever registry: BM25 và scaffold cho graph/hybrid retrievers.
- BudgetRAG policies: legacy, char-budget, per-doc-budget, score-density, sentence-trim, evidence-aware, adaptive-heuristic.
- Adaptive profiles: conservative, balanced, aggressive.
- RLAIIF data: rlaif_actions.jsonl, rlaif_feedback.jsonl, rlaif_rewards.jsonl, rlaif_preferences.jsonl.
- Labelers: rlaif-label-answers, rlaif-label-contexts, rlaif-label-pairs.

- Selectors: fixed, cheapest, best-average, family-smoothed, shrinkage-smoothed, linear reward model, smoothed linear selector, oracle logged.

5 Phase 1A: nền tảng benchmark RAG

Phase 1A xây nền cho toàn bộ các phase sau: CLI benchmark, retriever registry, metric retrieval và cấu trúc output có thể trace. Các metric nền gồm hit@k, MRR, nDCG, latency, context token/char counts và metadata để join kết quả sau này. Ý nghĩa chính của phase này là biến hệ thống từ chatbot/RAG thủ công thành benchmark pipeline có thể chạy lại.

Các tập như SciFact/NFCorpus và BEIR-style interfaces tạo nền cho retrieval validation. Kết quả định tính từ phase này phù hợp với BEIR: BM25 mạnh với claim/query có lexical overlap cao, còn semantic/hybrid retrievers có thể hữu ích ở domain khác. Báo cáo này không bịa thêm số Phase 1A vì các report numeric chi tiết không nằm trong danh sách nguồn hiện tại; thay vào đó các số định lượng bắt đầu từ Phase 1B/1C.

6 Phase 1B: BudgetRAG context policies

Phase 1B thêm các fixed context policies để kiểm soát lượng context đưa vào generator:

Policy	Ý nghĩa
legacy	Baseline giữ context theo cách cũ dưới budget matrix.
char-budget	Cắt theo tổng số ký tự.
per-doc-budget	Phân budget theo từng document để giảm dominance của một tài liệu dài.
score-density	Ưu tiên đoạn có retrieval score/length tốt hơn.
sentence-trim	Cắt theo câu để tránh cắt ngang bằng chứng.
evidence-aware	Giữ đoạn lexical/query-aware evidence; không phải entailment verifier và không answer-aware.

Smoke run Phase 1B trên 10 SciFact queries, BM25, top-k 3, generation skipped, Qwen2.5-14B KV profile cho thấy policy budget 1000 giữ khoảng 999.7–1002 chars, compression khoảng 0.216, token savings khoảng 960–961 và KV savings khoảng 900. Đây là smoke test metric plumbing; quality trông vì generation bị skip.

Policy/budget	Queries	Kept chars	Compression	KV savings
char-budget 1000	10	999.7	0.2161	900.9
evidence-aware 1000	10	999.7	0.2162	900.9
legacy 1000	10	1002.0	0.2167	900.4
char-budget 4000	10	3906.0	0.8380	219.6
evidence-aware 4000	10	3999.0	0.8647	219.7

Kết luận Phase 1B: budget thấp tạo token/KV savings lớn như kỳ vọng, nhưng retrieval-only smoke chưa nói được answer quality.

7 Phase 1C: adaptive heuristic profiles

Phase 1C chuyển từ fixed policy sang deterministic adaptive heuristic. Selector dùng retrieval diagnostics như score gap, score entropy, confidence và long-document dominance để chọn context policy/budget.

Phase 1C smoke trên 10 SciFact BM25 queries chọn evidence-aware và budget 4000 cho cả 10 queries, với reason chủ yếu là flat retrieval scores. Phase 1C.1 mở rộng lên 50 queries: selected policy counts là evidence-aware: 48 và per-doc-budget: 2; selected budget counts vẫn là 4000 cho 50/50 queries. Điều này xác nhận metadata ổn nhưng heuristic quá conservative.

Phase 1C.2 thêm profile conservative/balanced/aggressive và normalized diagnostics. Bảng sau tóm tắt các điểm đáng chú ý từ SciFact BM25, 50 queries, top-k 5:

Profile	Matrix budget	Kept chars	Compression	Selected budgets
conservative	1000	4000	0.4991	4000: 50
balanced	1000	2260	0.2816	1000: 29; 4000: 21
aggressive	1000	999.8	0.1248	1000: 50
aggressive	2000	1360	0.1665	1000: 32; 2000: 18

Balanced/aggressive tạo đa dạng budget hơn conservative. Feature diagnostics cho balanced medium budget 1000 có normalized score gap mean 0.2012, normalized entropy mean 0.9861 và score confidence mean 0.0043. Entropy cao giải thích vì sao conservative dễ chọn context lớn. Phase 1C vẫn là deterministic heuristic, không phải learned policy.

8 Phase 1C.3: generation feedback layer

Retrieval-only metrics không trả lời được câu hỏi: context đã nén có còn đủ hỗ trợ answer hay không. Phase 1C.3 thêm generation matrix và feedback layer:

- Joined 192 completed RAGAS samples từ 64 action files về BudgetRAG query_results.jsonl.
- Action coverage gồm MiMo 96 rows, Llama 3.1 8B 48 rows, Qwen3 32B 48 rows; context policies gồm adaptive-heuristic 96, evidence-aware 48, legacy 48.
- RAGAS answer relevancy là proxy ban đầu; sau đó MiMo answer labels cung cấp correctness/support/unsupported-claim signal.

Full MiMo answer labels:

Metric	Value
Label count	192
Valid JSON	192
Invalid JSON	0
Ambiguous labels	25
Judge errors	1
Scored labels	191
MiMo quality vs RAGAS answer relevancy correlation	0.277

Correlation 0.277 cho thấy RAGAS và MiMo đo các khía cạnh liên quan nhưng không đồng nhất. Vì vậy RAGAS-only reward chỉ là proxy ban đầu; MiMo labels giúp bổ sung correctness, support và unsupported-claim penalties.

9 Phase 1D: RLAIF reward và preference pipeline

Phase 1D biến BudgetRAG outputs thành dataset RLAIF-style:

Command	Vai trò
<code>rlaif-build</code>	Chuẩn hóa BudgetRAG rows thành action/feedback rows.
<code>rlaif-label-answer</code>	AI judge answer correctness/support/unsupported claims.
<code>rlaif-label-context</code>	AI judge context sufficiency, useful/redundant/irrelevant chunks.
<code>rlaif-reward</code>	Tạo scalar rewards và pairwise preferences với guardrails.
<code>rlaif-split</code>	Split theo benchmark + query_id để tránh leakage action-row.
<code>rlaif-train/eval</code>	Train/evaluate offline selector baselines.
<code>rlaif-label-pairs</code>	Direct pairwise AI judge audit cho preference calibration.

Reward builder giữ provenance và missing reasons; missing feedback không thành 0. Preference có hai loại chính: `context_policy_preference` trong cùng retriever/model/query group, và `retrieval_context_preference` để so retrieval-context actions rộng hơn. Quality guardrail chặn action rẻ hơn nếu làm tụt quality quá rõ.

10 Kết quả chính

10.1 Full MiMo context labels

Full context-label pass đã merge đủ 192 action rows:

Metric	Value
Action count	192
Merged label count	192
Clean usable labels	177
Ambiguous labels	15
Invalid JSON labels	0
Error count	1
Sufficient contexts	110
Insufficient contexts	76
Sufficiency rate	0.591
Mean selected chunks	1.276
Mean redundant chunks	0.286
Mean irrelevant chunks	3.708
Mean context quality	0.602
Mean evidence support	0.556
Mean minimality	0.947

Điểm quan trọng là judge thường chỉ chọn khoảng 1–2 chunks hữu ích nhưng đánh dấu trung bình 3.708 irrelevant chunks. Answer-level reward một mình có thể bỏ qua nhiều này; context-level RLAIF làm rõ context sufficiency và evidence minimality.

10.2 Context reward ablation

Context labels được merge vào reward bằng flag non-default. Default answer-only vẫn giữ nguyên. Với context penalty 0.25/0.50/1.00:

Setting	Preferences	Changed rows	Negative deltas	Mean changed delta
answer-only	722	–	–	–
context penalty 0.25	952	140	108	-0.212
context penalty 0.50	946	140	108	-0.316
context penalty 1.00	944	140	108	-0.525

Context-level RLAIIF materially changes reward/preference construction. Penalty 0.25 là conservative candidate; penalty 1.00 là aggressive diagnostic setting vì làm giảm reward scale mạnh.

10.3 Multi-seed selector results

Các selector được evaluate bằng six-seed held-out splits theo benchmark + query_id; tất cả đều offline và runtime_default_replacement=false. Bảng answer-only:

Policy	Coverage	Reward	Quality	Oracle gap
cheapest	1.000	0.577 ± 0.159	0.770 ± 0.152	0.094
best_average	0.911	0.618 ± 0.147	0.794 ± 0.125	0.080
shrinkage_smoothed	1.000	0.602 ± 0.117	0.773 ± 0.097	0.070
linear_reward_model	1.000	0.586 ± 0.153	0.774 ± 0.110	0.086
smoothed_linear	1.000	0.595 ± 0.137	0.767 ± 0.122	0.076
oracle_logged	1.000	0.671 ± 0.134	0.834 ± 0.138	0.000

Bảng context penalty 0.25:

Policy	Coverage	Reward	Quality	Oracle gap
cheapest	1.000	0.451	0.704	0.093
best_average	0.911	0.478	0.701	0.085
shrinkage_smoothed	1.000	0.449	0.683	0.095
smoothed_linear	1.000	0.472	0.689	0.072
oracle_logged	1.000	0.544	0.755	0.000

Context reward làm giảm absolute reward scale vì phạt insufficient/noisy context. Learned selectors chưa robustly beat simple baselines. Kết luận đúng là hạ tầng hoạt động, nhưng bottleneck hiện tại là logged action coverage, retriever diversity và supervision, không phải thiếu thuật toán RL phức tạp.

11 Pairwise RLAIIF audit và calibration

Direct pairwise MiMo-50 audit so sánh reward-derived preference với judge preference trực tiếp:

Metric	Value
Pair labels	50
Valid JSON	50
Invalid JSON	0
Ambiguous timeout labels	2
A/reward-chosen wins	41
B/rejected wins	7
Agreement over non-ambiguous	0.854
Mean confidence	0.914

Calibration diagnostics:

Metric	Value
Valid decisions	48
Small quality/support delta pairs	38
Cheaper wins when quality/support tied	35
Cheaper-win rate when tied	0.921
Scalar-over-quality disagreements	5
Disagreement rate	0.104
Candidate quality/support thresholds	0.10 / 0.20

Scalar reward mostly aligns with direct judge preference, but disagreements xuất hiện khi quality/support chênh lệch nhỏ và cheaper action được judge thích hơn. Điều này dẫn đến candidate pairwise_tie_v1; hiện nó ảnh hưởng preference construction/audit, chưa phải pairwise-trained selector.

12 Offline selector / bandit baselines

Các selector hiện có:

Selector	Ý nghĩa
fixed	Chọn một exact signature phổ biến nhất; coverage thấp.
cheapest	Chọn action rẻ nhất theo token/latency/KV.
best_average	Chọn exact signature có train mean reward cao nhất.
family_smoothed_best_average	Backoff exact signature → retrieval-context family → context policy.
shrinkage_smoothed_best_average	Shrink exact/family/context means về global mean để giữ coverage.
linear_reward_model	Ridge/linear baseline từ action/cost features không leak eval reward.
smoothed_linear_selector	Thêm train-only aggregate reward features vào linear selector.
oracle_logged	Upper bound trong logged candidates; không deploy được.

Action coverage diagnostics giải thích vì sao learned selector chưa thắng ổn định:

Level	Unique	Singleton rate	Mean split group coverage
action_id	192	1.000	0.000
exact_signature	77	0.260	0.911
retrieval_context_family	16	0.000	1.000
context_policy	3	0.000	1.000

Exact signatures giữ ranking signal tốt nhưng sparse; family/shrinkage smoothing sửa coverage. Shrinkage-smoothed best average hiện là full-coverage non-oracle baseline mạnh nhất về mean reward/oracle gap, nhưng best-average vẫn có quality/reward cao hơn khi nó cover được.

13 Multi-judge targeted audit

Sau full MiMo context labels, targeted audit dùng DeepSeek v4 Flash và Groq Qwen3 32B làm secondary judges cho 60 high-impact rows. DeepSeek chạy đủ 192 actions rồi lọc về subset 60; Groq chạy 60 rows

bằng local/Kaggle shards.

Judge	Labels	Valid	Ambiguous	Clean sufficiency
MiMo	60	60	0	57
DeepSeek	60	60	10	50
Groq	60	60	11	49

Pair	Compared	Agree	Agreement rate
MiMo vs DeepSeek	47	43	0.915
MiMo vs Groq	46	40	0.870
DeepSeek vs Groq	41	39	0.951

Audit signals: 51/60 consensus-insufficient rows, 55/60 majority-insufficient rows và 6 MiMo-harsh/high-disagreement rows. Kết luận: targeted selector đang tìm đúng các context yếu; MiMo không có vẻ quá harsh toàn cục, nhưng 6 disagreement rows phải được inspect trước khi tăng context penalty hoặc dùng label làm clean evidence-mask supervision.

14 KV-cache motivation và Qwen estimates

KV-cache ước tính theo công thức:

$$\text{KV bytes} \approx 2 \times L \times H_{kv} \times D_{head} \times S \times B \times \text{bytes_per_value}$$

Trong đó L là số layer, H_{kv} là số KV heads, D_{head} là head dimension, S là sequence length, B là batch size. Với GQA/MQA models phải dùng `num_key_value_heads`, không dùng `num_attention_heads`.

Model	KV GiB @ 4K	KV GiB @ 32K	KV GiB @ 128K
Qwen2.5-0.5B	0.047	0.375	1.500
Qwen2.5-1.5B	0.109	0.875	3.500
Qwen2.5-3B	0.141	1.125	4.500
Qwen2.5-7B	0.219	1.750	7.000
Qwen2.5-14B	0.750	6.000	24.000

Các số này chỉ là KV-cache estimates. Chúng không bao gồm model weights, activations, allocator overhead, paged-attention block overhead hay runtime workspaces. Ý nghĩa với BudgetRAG: giảm context trước inference có tác động trực tiếp lên KV estimate; context-level evidence labels sau này có thể giúp giữ sink/recent/evidence tokens khi làm KV pruning POC.

15 Giới hạn

- Feedback hiện là RLAIIF-style AI feedback, không phải human labels.
- Evaluation là offline logged-candidate evaluation, không phải online deployment.
- Action logs còn nhỏ; split held-out theo query nhưng eval groups vẫn ít.

- Retriever diversity thấp; kết quả hiện hỗ trợ context-budget/action selection mạnh hơn retrieval-strategy selection.
- Context reward là non-default candidate.
- Pairwise RLAIIF hiện dùng để audit/calibrate reward, chưa train pairwise ranker.
- Chưa có DPO/PPO/GRPO, chưa có online RL.
- Chưa có production runtime KV pruning.
- Web-search actions nếu có chỉ là live stress test, không được trộn với BEIR-style reproducible benchmark claims.

16 Công việc tiếp theo

Ưu tiên tiếp theo:

1. Inspect 6 MiMo-harsh rows và consensus-insufficient examples để calibrate context penalty.
2. Retriever-diversity logging với BM25, graph-BM25, hybrid-RRF; cần bước này trước khi claim retrieval-strategy selection.
3. Tăng số query groups để giảm variance giữa split seeds.
4. Context-label-aware selector dùng sufficiency/evidence labels trực tiếp hơn.
5. Pairwise ranker sau khi có đủ direct pairwise labels.
6. Local Qwen/KV profiling: full vs compressed context, prefill/decode latency, peak memory, estimated vs observed KV.
7. Runtime KV pruning POC ở phase sau: giữ sink/recent/evidence tokens, không làm trong Phase 1D hiện tại.

A Chi tiết Phase 1B–1C

Phase	Policy/profile	Queries	Kept chars	Compression	KV savings
1B	char-budget 1000	10	999.7	0.2161	900.9
1B	evidence-aware 1000	10	999.7	0.2162	900.9
1B	evidence-aware 4000	10	3999	0.8647	219.7
1C.1	adaptive-heuristic	50	4000	0.4991	1012
1C.2	conservative 1000	50	4000	0.4991	1012
1C.2	balanced 1000	50	2260	0.2816	1419
1C.2	aggressive 1000	50	999.8	0.1248	1715

B Reward ablation đầy đủ

Candidate	Policy	Coverage	Reward	Quality	Oracle gap
-----------	--------	----------	--------	---------	------------

answer-only	cheapest	1.000	0.577	0.770	0.094
answer-only	best_average	0.911	0.618	0.794	0.080
answer-only	shrinkage	1.000	0.602	0.773	0.070
answer-only	smoothed_linear	1.000	0.595	0.767	0.076
answer-only	oracle	1.000	0.671	0.834	0.000
penalty 0.25	cheapest	1.000	0.451	0.704	0.093
penalty 0.25	best_average	0.911	0.478	0.701	0.085
penalty 0.25	shrinkage	1.000	0.449	0.683	0.095
penalty 0.25	smoothed_linear	1.000	0.472	0.689	0.072
penalty 0.25	oracle	1.000	0.544	0.755	0.000
penalty 0.50	cheapest	1.000	0.386	0.704	0.104
penalty 0.50	best_average	0.911	0.420	0.701	0.091
penalty 0.50	shrinkage	1.000	0.389	0.683	0.100
penalty 0.50	smoothed_linear	1.000	0.415	0.689	0.074
penalty 0.50	oracle	1.000	0.489	0.755	0.000
penalty 1.00	cheapest	1.000	0.255	0.704	0.132
penalty 1.00	best_average	0.911	0.303	0.701	0.109
penalty 1.00	shrinkage	1.000	0.273	0.689	0.114
penalty 1.00	smoothed_linear	1.000	0.329	0.703	0.058
penalty 1.00	oracle	1.000	0.387	0.748	0.000

C CLI chronology

```
rag-bench run / scripts/run_budgetrag_matrix.py
scripts/summarize_budgetrag_results.py
rag-bench rlaif-build
rag-bench rlaif-label-answers
rag-bench rlaif-label-contexts
rag-bench rlaif-reward
rag-bench rlaif-split
rag-bench rlaif-train
rag-bench rlaif-eval
rag-bench rlaif-label-pairs
scripts/summarize_rlaif_labels.py
scripts/summarize_rlaif_context_labels.py
scripts/validate_rlaif_context_labels.py
scripts/run_context_reward_ablation_pipeline.py
scripts/aggregate_rlaif_multijudge_audit.py
```

D Các report nguồn

Các số trong báo cáo được lấy từ:

- docs/reports/phase1b_smoke_results.md
- docs/reports/phase1c_adaptive_smoke_results.md
- docs/reports/phase1c1_adaptive_validation.md
- docs/reports/phase1c2_adaptive_threshold_calibration.md

- docs/reports/phase1d_rlaif_selector_smoke.md
- docs/reports/phase1d_rlaif_heldout_eval.md
- docs/reports/phase1d_rlaif_ai_judge_heldout_eval.md
- docs/reports/phase1d_rlaif_pairwise_mimo50.md
- docs/reports/phase1d_rlaif_pairwise_calibration_diagnostics.md
- docs/reports/phase1d_rlaif_v2_multiseed_selector_eval.md
- docs/reports/phase1d_rlaif_action_coverage.md
- docs/reports/phase1d_rlaif_v2_family_smoothed_selector_eval.md
- docs/reports/phase1d_rlaif_v2_smoothed_linear_selector_eval.md
- docs/reports/phase1d_rlaif_v2_shrinkage_selector_eval.md
- docs/reports/phase1d_rlaif_context_labels_mimo50.md
- docs/reports/phase1d_rlaif_context_reward_candidate.md
- docs/reports/phase1d_rlaif_full_context_reward_ablation.md
- docs/reports/phase1d_rlaif_multijudge_audit.md
- docs/reports/local_qwen_kv_estimates.md

Tài liệu

- [1] Yuntao Bai, Saurav Kadavath, Sandipan Kundu, Amanda Askell, Jackson Kernion, Andy Jones, Anna Chen, Anna Goldie, Azalia Mirhoseini, Cameron McKinnon, Carol Chen, Catherine Olsson, Chris Olah, Danny Hernandez, Dawn Drain, Deep Ganguli, Dustin Li, Eli Tran-Johnson, Ethan Perez, Jamie Kerr, Jared Mueller, Jeffrey Ladish, Joshua Landau, Kamal Ndousse, Kamile Lukosuite, Liane Lovitt, Michael Sellitto, Nelson Elhage, Nicholas Schiefer, Nova DasSarma Mercado, Robert Lasenby, Robin Larson, Sam Ringer, Scott Johnston, Shauna Kravec, Sheer Showk, Stanislav Fort, Tamera Lanham, Timothy Telleen-Lawton, Tom Conerly, Tom Henighan, Tristan Hume, Samuel R. Bowman, Zac Hatfield-Dodds, Ben Mann, Dario Amodei, Nicholas Joseph, Sam McCandlish, Tom Brown, and Jared Kaplan. Constitutional ai: Harmlessness from ai feedback. *arXiv preprint arXiv:2212.08073*, 2022. <https://arxiv.org/abs/2212.08073>.
- [2] Zefan Cai, Yichi Zhang, Bofei Gao, Yuliang Liu, Tianyi Liu, Keming Lu, Wayne Xiong, Yue Dong, Baobao Chang, Junjie Hu, and Wen Xiao. Pyramidkv: Dynamic kv cache compression based on pyramidal information funneling. *arXiv preprint arXiv:2406.02069*, 2024. <https://arxiv.org/abs/2406.02069>.
- [3] Gordon V. Cormack, Charles L. A. Clarke, and Stefan Buettcher. Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 758–759, 2009. <https://doi.org/10.1145/1571941.1572114>.
- [4] Darren Edge, Ha Trinh, Newman Cheng, Joshua Bradley, Alex Chao, Apurva Mody, Steven Truitt, and Jonathan Larson. From local to global: A graph rag approach to query-focused summarization. *arXiv preprint arXiv:2404.16130*, 2024. <https://arxiv.org/abs/2404.16130>.

- [5] Shahul Es, Jithin James, Luis Espinosa-Anke, and Steven Schockaert. Ragas: Automated evaluation of retrieval augmented generation. *arXiv preprint arXiv:2309.15217*, 2023. <https://arxiv.org/abs/2309.15217>.
- [6] Huiqiang Jiang, Qian Wu, Chin-Yew Lin, Yuqing Yang, and Lili Qiu. Llmmlingua: Compressing prompts for accelerated inference of large language models. *arXiv preprint arXiv:2310.05736*, 2023. <https://arxiv.org/abs/2310.05736>.
- [7] Huiqiang Jiang, Qian Wu, Xufang Luo, Dongsheng Li, Chin-Yew Lin, Yuqing Yang, and Lili Qiu. Longllmlingua: Accelerating and enhancing llms in long context scenarios via prompt compression. *arXiv preprint arXiv:2310.06839*, 2023. <https://arxiv.org/abs/2310.06839>.
- [8] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Kuttler, Mike Lewis, Wen-tau Yih, Tim Rocktaschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive nlp tasks. *arXiv preprint arXiv:2005.11401*, 2020. <https://arxiv.org/abs/2005.11401>.
- [9] Lihong Li, Wei Chu, John Langford, and Robert E. Schapire. A contextual-bandit approach to personalized news article recommendation. *arXiv preprint arXiv:1003.0146*, 2010. <https://arxiv.org/abs/1003.0146>.
- [10] Yucheng Li, Bo Dong, Frank Guerin, and Chenghua Lin. Compressing context to enhance inference efficiency of large language models. *arXiv preprint arXiv:2310.06201*, 2023. <https://arxiv.org/abs/2310.06201>.
- [11] Yuhong Li, Yingbing Huang, Bowen Yang, Bharat Venkitesh, Andrea Locatelli, Hanchen Ye, Tian Cai, Patrick Lewis, and Deming Chen. Snapkv: Llm knows what you are looking for before generation. *arXiv preprint arXiv:2404.14469*, 2024. <https://arxiv.org/abs/2404.14469>.
- [12] Zirui Liu, Jiayi Yuan, Hongye Jin, Shaochen Zhong, Zhaozhuo Xu, Vladimir Braverman, Beidi Chen, and Xia Hu. Kivi: A tuning-free asymmetric 2bit quantization for kv cache. *arXiv preprint arXiv:2402.02750*, 2024. <https://arxiv.org/abs/2402.02750>.
- [13] Rafael Rafailov, Archit Sharma, Eric Mitchell, Stefano Ermon, Christopher D. Manning, and Chelsea Finn. Direct preference optimization: Your language model is secretly a reward model. *arXiv preprint arXiv:2305.18290*, 2023. <https://arxiv.org/abs/2305.18290>.
- [14] Nandan Thakur, Nils Reimers, Andreas Ruckle, Abhishek Srivastava, and Iryna Gurevych. Beir: A heterogeneous benchmark for zero-shot evaluation of information retrieval models. *arXiv preprint arXiv:2104.08663*, 2021. <https://arxiv.org/abs/2104.08663>.
- [15] Guangxuan Xiao, Yuandong Tian, Beidi Chen, Song Han, and Mike Lewis. Efficient streaming language models with attention sinks. *arXiv preprint arXiv:2309.17453*, 2023. <https://arxiv.org/abs/2309.17453>.
- [16] Zhenyu Zhang, Ying Sheng, Tian Zhou, Tian Chen, Lianmin Zheng, Ruisi Cai, Zhao Song, Yuandong Tian, Christopher Re, Clark Barrett, Zhangyang Wang, and Beidi Chen. H2o: Heavy-hitter oracle for efficient generative inference of large language models. *arXiv preprint arXiv:2306.14048*, 2023. <https://arxiv.org/abs/2306.14048>.