
BudgetRAG / MemAlign-Qwen

RLAIF-guided retrieval, offline bandit, and local Qwen/KV roadmap

Học chính sách chọn retrieval và cấp phát ngữ cảnh cho grounded LLM inference dưới ngân sách token, latency và KV-cache ước lượng.

Phase 1D research deck
cập nhật từ kết quả đã chạy

Câu hỏi nghiên cứu

Khi cùng một query có nhiều cách truy xuất và nhiều mức nén context,
chọn hành động nào để câu trả lời vẫn grounded với chi phí thấp hơn?

Quyết định

Retriever, fusion và context policy cùng thuộc action space.

Ngân sách

Token, latency và KV-cache là cost trực tiếp, không chỉ là log phụ.

Ranh giới claim

Policy học offline từ logged outcomes; PPO/GRPO, human preference learning và production KV pruning nằm ngoài phase này.

Chiến lược Phase 1D



State

Query features, retrieval score gap/entropy, document length statistics, retriever/model metadata.

Action


retrieval strategy + fusion + context policy + budget/adaptive profile.

Objective

Tối đa grounded quality sau khi trừ token, latency, estimated KV và lỗi generation.

Các slide kế tiếp định nghĩa action, reward và thuật toán trước; phần data chỉ dùng để kiểm tra trade-off của strategy này.

RLAIF nằm ở nhiều điểm của pipeline



Định nghĩa dùng trong deck

RLAIF là AI feedback dùng làm nhãn chất lượng/preference. Judge chỉ nhìn question, retrieved context và answer; không browse và không dùng external knowledge.

Tác dụng với bandit

Retrieval-only metrics không biết answer có được support hay không. RLAIF thêm groundedness, unsupported-claim và evidence sufficiency vào reward.

Context policy và action space

Term	Định nghĩa trong project
legacy/full	Giữ rank order và nối block context; full nghĩa là không đặt action budget riêng, chỉ chịu ceiling prompt/top-k đang có.
char-budget	Lắp một global character budget theo rank order; trim block cuối nếu vượt budget.
per-doc-budget	Cắt từng document trước rồi mới lắp global budget để tránh một document dài chiếm toàn bộ context.
score-density	Ưu tiên <code>retrieval_score</code> / <code>estimated_tokens</code> ; fallback 1 / <code>estimated_tokens</code> nếu thiếu score.
sentence-trim	Giữ rank order nhưng trim tại ranh giới câu đơn giản khi có thể.
evidence-aware	Tên CLI tương thích cũ; implementation hiện tại là lexical-query-aware : tách span, chấm bằng query overlap + retrieval score + title overlap.
adaptive-heuristic	Selector theo luật chọn fixed policy + budget dựa trên score gap, entropy và document length; đây là baseline trước bandit, chưa phải RL.

Profiles: **conservative** ưu tiên budget lớn khi retrieval không chắc; **balanced** tách ngân sách theo score gap/entropy; **aggressive** stress-test budget nhỏ hơn.

Reward: tính cụ thể từng thành phần

$$R = w_q Q_{\text{answer}} + w_s S_{\text{evident}} - w_t C_{\text{tok}} - w_l C_{\text{lat}} - w_k C_{\text{kv}} - w_e P_{\text{error}} - w_u P_{\text{unsupported}}$$

Quality/support từ RLAIIF

- ▶ Q_{answer} : overall_quality của answer judge; nếu thiếu thì dùng proxy reward và ghi rõ.
- ▶ S_{evident} : trung bình các tín hiệu evidence_support và context_quality_score.
- ▶ $P_{\text{unsupported}}$: unsupported_claim_penalty trong $[0, 1]$.
- ▶ P_{error} : 1 nếu generation/API/parsing lỗi, ngược lại 0.

Cost chuẩn hóa trong run

- ▶ C_{tok} : normalize prompt_tokens hoặc kept_est_tokens.
- ▶ C_{lat} : normalize answer_latency_s.
- ▶ C_{kv} : normalize estimated_kv_cache_mb_after.
- ▶ $\text{norm}(x) = \frac{x - \min(x)}{\max(x) - \min(x) + \varepsilon}$, theo dataset/model/run.

Default weights: $w_q = 1.0, w_s = 0.2, w_t = 0.2, w_l = 0.2, w_k = 0.1, w_e = 1.0, w_u = 1.0$. Tất cả nên là tham số CLI.

Offline contextual bandit: thuật toán

Với mỗi query, policy chọn một action. Reward đến từ logged outcome; không tương tác online với người dùng.

Input row

query id, state features, action id, outcome metrics, optional RLAIIF labels.

Policies

FixedAction, Cheapest, BestAverage, OracleLogged, epsilon-greedy replay, UCB, linear reward model.

Evaluation

split train/test theo query_id; report reward, quality, token, latency, KV, error rate và action distribution.

- 1. Observe
- 2. Choose
- 3. Score
- 4. Learn

tính state s trước generation từ query và retrieval candidates.
chọn $a = (retriever, fusion, context\ policy, budget, profile)$.
build reward từ RLAIIF/cost/error.
update policy offline; nếu action chưa quan sát đủ thì report limitation.

Triển khai RLAIIF và bandit trong repo

RLAIIF path

theo Phase 1D plan

- ▶ `rlaif_schema.py`: validate context/answer judge JSON.
- ▶ `label_contexts_with_rlaif.py`: chọn evidence tối thiểu, sufficiency, minimality.
- ▶ `label_answers_with_rlaif.py`: correctness, support, hallucination/refusal/citation.
- ▶ thiếu credential thì bỏ qua có log rõ ràng; không in secret.

Bandit path

logged data trước, policy sau

- ▶ `build_budgetrag_logged_dataset.py`: gom state/action/outcome.
- ▶ `build_budgetrag_rewards.py`: normalize cost và merge RLAIIF labels.
- ▶ `retrieval_context_actions.py`: định nghĩa action set.
- ▶ `train/evaluate_budget_bandit.py`: baselines, replay, UCB, linear reward model.

Đây là contextual bandit/RL-lite. Không gọi là full RL nếu chưa có trajectory nhiều bước hoặc online policy improvement.


Kết quả thực nghiệm: retrieval benchmark

Dataset	Retriever	hit@3	nDCG@3	latency/q
SciFact	BM25	0.82	0.7619	0.021s
SciFact	hybrid-RRF	0.86	0.7988	0.031s
SciFact	vector-rerank	0.84	0.8011	0.028s
NFCorpus	BM25	0.56	0.3151	0.008s
NFCorpus	vector	0.68	0.3796	0.015s
NFCorpus	hybrid-RRF	0.66	0.3874	0.019s

Đọc kết quả

Hybrid/vector hữu ích trên semantic datasets; BM25 vẫn là baseline mạnh với latency thấp.

hit@3 theo retriever



LLM query rewrite/multi-query tăng latency khoảng 1.4–2.4s/query và chưa vượt BM25 trên SciFact.


BudgetRAG context: Phase 1C.3 snapshot

Model / action	q	kept chars	token saved	KV saved
Llama8B adapt-aggr 1k	50	999.8	1829	1715 MB
Qwen3-32B adapt-bal 1k	50	2260	1514	1419 MB
MiMo adapt-bal 1k	50	2260	1514	1419 MB
MiMo-L adapt-aggr 4k	30	2200	3488	3270 MB
MiMo-L evidence 32k	30	26120	0	0 MB

Nguồn

File snapshot: phase1c3_snapshot_summary.md trong benchmark_results/budgetrag/. Các hàng này là aggregate snapshot; không đưa raw answers/API logs vào slide.

KV saved, MB



Adaptive chọn evidence-aware gần như toàn bộ và chỉ dùng per-doc-budget cho long-document dominance.


Kết quả thực nghiệm: generation matrix

Matrix	Gen.	Errors	latency	prompt tok.
Groq Llama 8B, SciFact BM25	800	61	15.47s	816.5
MiMo v2.5 Pro, SciFact BM25	800	0	8.76s	866.8
MiMo long context, top-k 10	480	0	11.26s	2379.3

Tổng hợp context/KV

Full Groq/MiMo matrix giữ trung bình 824.7 context tokens; KV ước lượng sau budget khoảng 760 MB, tiết kiệm khoảng 1189 MB.

Latency, seconds



Long-context stress test

MiMo long-context giữ trung bình 2398 context tokens; KV sau budget khoảng 1959 MB, tiết kiệm khoảng 1827 MB.

Data đọc như thế nào cho policy

Retrieval action

SciFact cho thấy BM25 vẫn là action rẻ và mạnh; hybrid/vector chỉ đáng chọn khi reward bù được build/latency cost.

Context action

Phase 1C.3 cho thấy budget nhỏ có thể tiết kiệm token/KV lớn, nhưng reward phải bảo vệ evidence sufficiency.

Generator action

MiMo long-context mở upper bound cho context dài; Groq lỗi nhiều hơn trong matrix này nên error penalty phải nằm trong reward.

Kết luận không phải “policy nhỏ nhất luôn tốt”, mà là cần học action theo state để tránh mất evidence ở các query khó.

Qwen2.5 KV-cache @ 1k / 16k / 128k

Model	layers	KV heads	head dim	1k	16k	128k
Qwen2.5-0.5B	24	2	64	12 MiB	192 MiB	1.5 GiB
Qwen2.5-1.5B	28	2	128	28 MiB	448 MiB	3.5 GiB
Qwen2.5-3B	36	2	128	36 MiB	576 MiB	4.5 GiB
Qwen2.5-7B	28	4	128	56 MiB	896 MiB	7.0 GiB
Qwen2.5-14B	48	8	128	192 MiB	3.0 GiB	24.0 GiB

$$KV = 2 \times layers \times num_key_value_heads \times head_dim \times seq \times batch \times dtype_bytes$$

Assumption: batch=1, fp16/bf16. 1k = 1024 tokens, 16k = 16384, 128k = 131072. KV tăng tuyến tính theo sequence length. Bảng dùng KV heads/GQA; các run cũ dùng profile analytical qwen2.5-14b conservative hơn.

Local Qwen và roadmap KV

Estimator/profiling

- ▶ đọc model config, không load weights cho estimate;
- ▶ start Qwen2.5 0.5B/1.5B nếu có GPU;
- ▶ đo prompt tokens, output tokens, prefill/decode latency, peak CUDA memory, estimated KV.

KV pruning POC

- ▶ prefill full/compressed context;
- ▶ capture `past_key_values`;
- ▶ retain sink + recent + RLAIIF evidence tokens;
- ▶ slice KV rồi decode continuation.

Phase 1D chỉ bao gồm estimate/profiling và POC nếu chạy thật; production KV-cache pruning nằm ngoài phạm vi.

Kế hoạch thực thi 7 ngày

Ngày	Trọng tâm	Kết quả cần có
1	Thu generation outputs	Phase 1C.3 logs, logged outcomes
2	Context RLAIIF	evidence chunks/spans, preference pairs
3	Answer RLAIIF	correctness/support/hallucination/refusal/citation labels
4	Reward	normalized token/latency/KV costs, reward JSONL
5	Bandit	baselines + bandit eval against fixed/adaptive heuristic
6	Local Qwen/KV	KV estimate table, small-model profiling if GPU available
7	Report	Phase 1D report, slide update, quyết định bước tiếp theo

Quyết định tiếp theo: runtime KV pruning POC hay DPO smoke, dựa trên evidence labels và profiling thật.

Ranh giới claim

Có thể nói

- ▶ đã có fixed/adaptive BudgetRAG policy và KV estimator;
- ▶ Phase 1C.3 snapshot có số liệu token/KV saving;
- ▶ Phase 1D đề xuất RLAIIF + offline contextual bandit;
- ▶ TurboQuant slide chỉ tính payload từ bit-width.

Không nói nếu chưa chạy

- ▶ đã có PPO/GRPO hoặc full RL;
- ▶ có human preference learning;
- ▶ Qwen14B DPO đã hoàn tất;
- ▶ runtime KV pruning production-ready;
- ▶ TurboQuant latency/quality/VRAM overhead khi chưa đo.

Deck này cố ý tách kết quả đã chạy, tính toán analytical và roadmap triển khai để tránh claim quá mức.

TurboQuant 16k/128k: tính payload chính xác

Công thức payload

$$TQ_{3.5b} = KV_{bf16} \times \frac{3+4}{16+16} = KV_{bf16} \times \frac{7}{32}$$

Giả định variant 3-bit key + 4-bit value. Đây chỉ là payload KV, chưa cộng metadata, packing alignment, kernel workspace hay allocator overhead.

Ví dụ kiểm tra

Qwen2.5-14B 16k bf16 KV = 3072 MiB.
 $3072 \times 7/32 = 672$ MiB.

Qwen2.5 KV payload nếu TurboQuant 3.5-bit

Model	16k TQ payload	128k TQ payload
Qwen2.5-0.5B	42 MiB	336 MiB
Qwen2.5-1.5B	98 MiB	784 MiB
Qwen2.5-3B	126 MiB	1008 MiB
Qwen2.5-7B	196 MiB	1568 MiB
Qwen2.5-14B	672 MiB	5376 MiB

128k Qwen2.5-14B: $24576 \times 7/32 = 5376$ MiB. Không dùng headline 6x hoặc runtime savings khi chưa đo implementation cụ thể.

Kết thúc

Luận điểm chính

- ▶ action space đủ hẹp để chạy offline bandit, nhưng vẫn bao phủ retriever, fusion, policy và budget;
- ▶ RLAIIF biến “context có vẻ tốt” thành label đo được: evidence đủ, answer được support, claim không bịạ;
- ▶ KV-cache được đưa vào reward như cost, chưa claim runtime pruning khi chưa đo.

Quyết định tiếp theo

- ▶ chốt label schema cho context/answer RLAIIF;
- ▶ chạy logged-outcome matrix đủ lớn cho bandit eval;
- ▶ profile local Qwen trước khi nói về runtime KV pruning hoặc TurboQuant gain thật.

Chốt: học policy từ logged outcomes; giữ groundedness làm điều kiện, tối ưu token/latency/KV như cost.